T.C.
İZMİR EKONOMİ ÜNİVERSİTESİ

MBP 200
GÖRSEL PROGRAMLAMA III

YAPAY ZEKA İLE GELECEK YIL GERÇEKLEŞECEK SİBER OLAYLARIN TAHMİNİ

20212425023
Mustafa Cüneyt Kafes

Öğretim Üyesi
Burak Evrentuğ

İZMİR - 2022

ÖZET

Gündelik hayatımızda gerçekleştirdiğimiz davranışlardan veya karşılaştığımız olaylardan yola çıkarak gelecekte başımıza gelebilecek durumların öngörülmesi, Makine öğrenmesi ile geliştirilen yapay zeka modelleri sayesinde daha da kolaylaşmış ve bu modeller günümüz sektörlerinde sıkça kullanmasıyla yaşamımızda oldukça yer edinmiştir.

Buna bağlı olarak, bahsi geçen yapay zeka sistemlerinin Siber Güvenlik alanında nasıl kullanılabileceği düşünülmüş ve gerçekleşme potansiyeli olan Siber Güvenlik olaylarının tespit edilmesi yönünde işbu proje geliştirilmiştir. Projenin amacı 2005-2020 tarihleri arasında Siber Güvenlik alanında gerçekleşmiş olan olayların analizini yaparak makine öğrenmesi ile geliştirilen yapay zeka modelinin geleceğe yönelik tahminlerde bulunmasını sağlamaktır.

Proje kapsamında python yazılım diliyle birlikte, “kaggle.com” isimli internet sitesi üzerinden temin edilen veri seti kullanılmıştır. Veri işleme ve görselleştirme kısımlarında matlab, pandas, numpy, seaborn, wordcloud kütüphaneleri, veri tahmin aşamasında yapay zekayı desteklemek için sklearn ve csv kütüphaneleri kullanılmıştır. İşlemler, colab online derleyicisi ve local (yerel) bilgisayar üzerinde bulunan PyCharm isimli IDE ile gerçekleştirilmiş ve test edilmiştir. Veri setleri beslenerek gelecek yıllarda Siber Güvenlik alanındaki olaylara yönelik tahmin sisteminin sürekli olarak gerçekleşmesi ve buna yönelik olarak tedbirlerin uygulanması sektörde bulunan tüzel kişiler tarafından beklenmektedir.

Anahtar kelimeler: Siber Güvenlik, Tahmin, Gelecek Yıl Siber Olaylar, Python

GİRİŞ

Gündelik hayatımızda gerçekleştirdiğimiz davranışlardan veya karşılaştığımız olaylardan yola çıkarak gelecekte başımıza gelebilecek durumların öngörülmesi, Makine öğrenmesi ile geliştirilen yapay zeka modelleri sayesinde daha da kolaylaşmış ve bu modeller günümüz sektörlerinde sıkça kullanmasıyla yaşamımızda oldukça yer edinmiştir.

Neredeyse her sektörde kullanılmaya başlayan ve popülerliği gittikçe artan Yapay Zeka modellerinin insanları korumaya yönelik alanlarda da kullanılması gerektiği düşünülmektedir. Teknolojinin sürekli geliştiği ve elektronik cihazların gündelik hayatımızda oldukça yer edindiği günümüz dünyasında ise internetin korunmaya ihtiyaç duyduğu en önemli hususlardan biri de sanal mecralardır. Sanal mecralarda insanları korumak öncelik olarak bilgi toplayan kurum ve kuruluşların görevidir. Siber Güvenlik alanında yeni sistemler sürekli olarak geliştirilmekte, kurum ve kuruluşların ise buna bağlı olarak kendi güvenlik sistemlerini güncel tutarak bilgi güvenliğini hizmet verdikleri insanlara sağlamaları ve mağduriyet yaşatmamaları gerekmektedir.

İşbu proje sayesinde, geçmiş yıllarda Siber Güvenlik alanında yaşanan olaylar incelenerek gelecek yılda yeni gelişmelerin ne yönde olacağı makine öğrenmesi ile geliştirilen yapay zeka modeli tarafından tahmin edilmektedir. Projedeki modelin kullanılmasıyla bahsi geçen şirketler, üretilen bu tahmin değerlerine göre belirli önlemler alabilecek ve mağduriyet potansiyelini en aza indirebileceklerdir. Projede kullanılan veri setinin beslenmesi ve gelecek yıllar için kullanılabilir hale getirilmesi sektörde aktif olarak yer alan tüzel kişilerden beklenmektedir.

Proje, Python programlama dili ile geliştirilmiş olup çeşitli 3. Taraf kaynaklı kütüphanelerden yararlanılmıştır.

Proje Siber Güvenlik alanında yer alan her gerçek ve tüzel kişi tarafından, iyi niyetli geliştirilmek üzere kullanılabilir

BÖLÜM 1
MEVCUT VERİLERİN TANIMI VE İNCELENMESİ

2005-2020 yılları arasında gerçekleşmiş olan Siber Güvenlik olaylarının bir kısmını içeren veri seti "kaggle.com" isimli internet sitesi üzerinden indirilmiş [0] ve projede kullanılacak olan kütüphaneler tanımlanmıştır. Yapılan işlemler aşağıdaki görselde yer almaktadır.

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from wordcloud import WordCloud, STOPWORDS

import numpy as np

import csv

from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error
from sklearn.preprocessing import PolynomialFeatures
from sklearn.ensemble import RandomForestRegressor
```

Pandas ve numpy kütüphanesi veri setinde bulunan veriler üzerinde işlemler yapmak, matplotlib ve seaborn kütüphaneleri veri görselleştirmeleri sağlamak, wordcloud veri setinde bulunan verilerin içeriğini görselleştirerek veriler hakkında genel bilgi sahibi olmak, csv kütüphanesi regresyon işlemi için yeni bir veri seti oluşturarak farklı dosyaya kaydetmek, sklearn kütüphanesi yapay zekayı eğitmek ve tahmin üretmek amaçlarıyla kullanılmıştır.

"kaggle.com" isimli internet sitesi üzerinden indirilen CSV uzantılı veri seti dosyası pandas kütüphanesi aracılığıyla okunarak, veri setinde bulunan ilk 5 satır kontrol amacıyla listelenmiştir. Aşağıda yapılan işlemlere ait görseller bulunmaktadır.

```
df = pd.read_csv('/content/drive/MyDrive/cyber-operations-incidents.csv')

df.head() # veri setimizdeki ilk 5 satırı listeliyoruz
```

	Title	Date	Affiliations	Description	Response	Victims	Sponsor	Type	Category	Sources_1	Sources_2	Sources_3
0	Attack on Austrian foreign ministry	2/13/2020	Turla	The suspected Russian hackers conducted a week...	Confirmation https://www.theregister.co.uk/2...	Austrian Foreign Ministry	Russian Federation	Espionage	Government	https://www.theregister.co.uk/2020/02/14/austr...	https://www.bmeia.gv.at/en/the-ministry/press/...	NaN
1	Spear-phishing campaign against unnamed U.S. g...	1/23/2020	Konni Group	The suspected North Korean threat actor Konni ...	NaN	Employees of the U.S. government	Korea (Democratic People's Republic of)	Espionage	Government	https://unit42.paloaltonetworks.com/the-fractu...	NaN	NaN
2	Australian Signals Directorate	4/6/2020	NaN	Responsible for attacking infrastructure that ...	NaN	NaN	Australia	Data destruction	Private sector	https://www.minister.defence.gov.au/minister/l...	https://www.zdnet.com/article/australia-on-the...	NaN
3	Catfishing of Israeli soldiers	2/16/2020	APT-C-23	The Hamas-associated threat actor APT-C-23 tar...	Hack Back https://www.bleepingcomputer.com/n...	Israeli Defense Forces (IDF) soldiers	Palestine, State of	Espionage	Military	https://www.bleepingcomputer.com/news/security...	https://research.checkpoint.com/2020/hamas-and...	NaN
4	Targeting of U.S. companies and government	8/10/2020	Fox Kitten	Iranian hackers attacked high-end	NaN	U.S. government agencies, U.S.	Iran (Islamic Republic of)	Espionage	Government, Private sector	https://www.cybersafe.news/fbi-warns-about-ira...	https://www.zdnet.com/article/fbi-says-an-iran...	NaN

Veri setindeki sütunların kontrolünü sağlanarak veri setinde boş değerlerin olup olmadığı hakkında bilgi sağlayabilmek için `df.isnull().values.any()` komutu, boş değerler bulunan veri sayısına ulaşmak için ise `df.isnull().sum()` komutu kullanılmıştır.

```
df.info() # veri setimizdeki sütunların kontrolünü sağlıyoruz
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 481 entries, 0 to 480
Data columns (total 12 columns):
 #   Column        Non-Null Count  Dtype 
---  ------        --------------  ----- 
 0   Title         481 non-null    object
 1   Date          474 non-null    object
 2   Affiliations  347 non-null    object
 3   Description   481 non-null    object
 4   Response      86 non-null     object
 5   Victims       453 non-null    object
 6   Sponsor       439 non-null    object
 7   Type          447 non-null    object
 8   Category      458 non-null    object
 9   Sources_1     475 non-null    object
 10  Sources_2     355 non-null    object
 11  Sources_3     168 non-null    object
dtypes: object(12)
memory usage: 45.2+ KB
```

```
df.isnull().values.any() # verilerde boşluk var mı ?
```

```
True
```

```
df.isnull().sum() # hangi sütunlarda ne kadar boşluk var
```

```
Title            0
Date             7
Affiliations   134
Description      0
Response       395
Victims         28
Sponsor         42
Type            34
Category        23
Sources_1        6
Sources_2      126
Sources_3      313
dtype: int64
```

WordCloud yapısı kullanılarak sahip olunan tüm veriler arasında en çok bulunan kelimeler görüntülenmiş, Verilerin içeriği hakkında genel bir bilginin tablo olarak sunulması amaçlanmıştır.

```
word_string = " ".join(df["Description"].str.lower()) # description sütunundaki verileri küçük karakter formatında birleştiriyoruz
wordcloud = WordCloud(stopwords=STOPWORDS, colormap='winter', background_color="white").generate(word_string) # wordcloud oluşturma kodu

fig, ax = plt.subplots(1, 1, figsize=(8, 8))
plt.clf()
plt.imshow(wordcloud)
plt.axis('off')
plt.title('Word Cloud (Tüm Veriler)', fontsize=18, c='black')
plt.show()
```

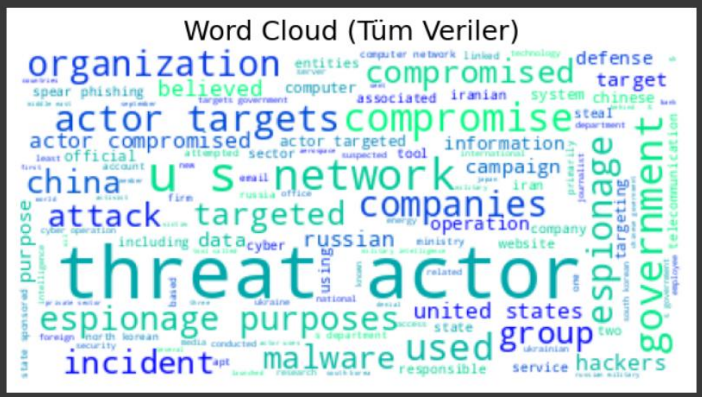

BÖLÜM 2
MEVCUT VERİLERE YÖNELİK İSTATİSTİKLER

Bu aşamada veriler görselleştirilerek, genelden özele doğru bir inceleme yapılmıştır. Bilgilerin görselleştirilme kısmında pasta grafiği (pie), sütun grafiği (barh ve bar plot), çizgi grafiği (line plot), saçılım grafiği (scatter plot) kullanılmıştır.

Aşağıdaki görselde 2005-2020 tarihleri arasında gerçekleşen siber saldırıların türlerine ait pasta grafiği yer almaktadır.

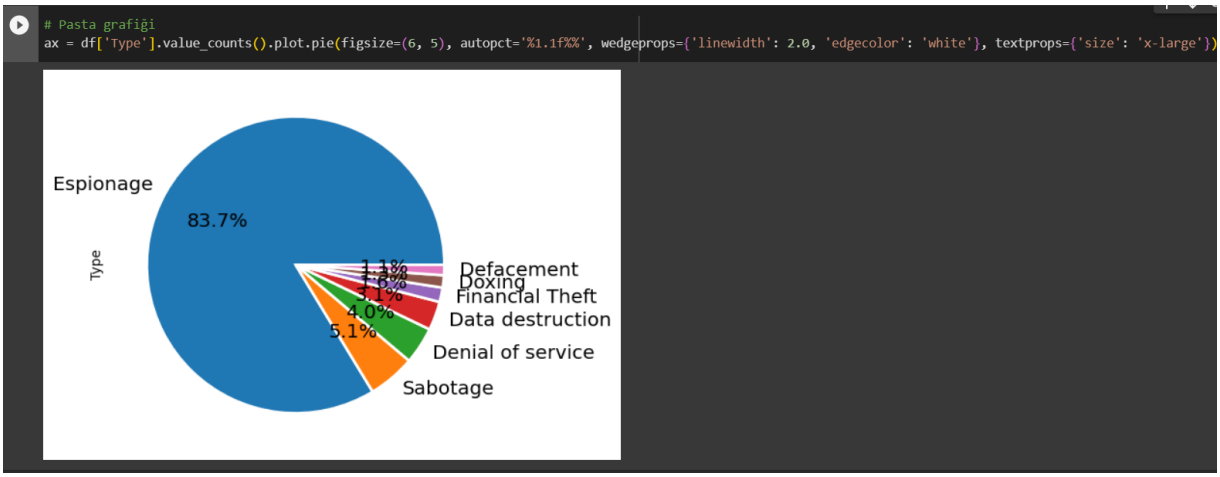

Aşağıdaki görselde 2005-2020 yılları arasında gerçekleşen saldırıların türlere göre sayısı sütun grafiği şeklinde yer almaktadır

```
# saldırı türlerini değişkene alıyoruz
saldiri_turleri = df['Type'].value_counts().index

# plot grafik oluşturuyoruz
fig, ax = plt.subplots(1, 1, figsize=(11, 3))
# veriyi tabloya yerleştirerek renk ayarlaması yapıyoruz
sns.countplot(data=df, x='Type', order=saldiri_turleri, palette='Spectral')

# alt kısım için yazı
ax.set(xlabel='Saldırı Türleri')
# sol kısım için yazı
ax.set(ylabel='Saldırı Sayısı')

# grafik başlığı
plt.title('2005-2020 Yılları Arasında Gerçekleşen Saldırı Türlerinin Sayısı', fontsize=16, c='black')
plt.show()
```

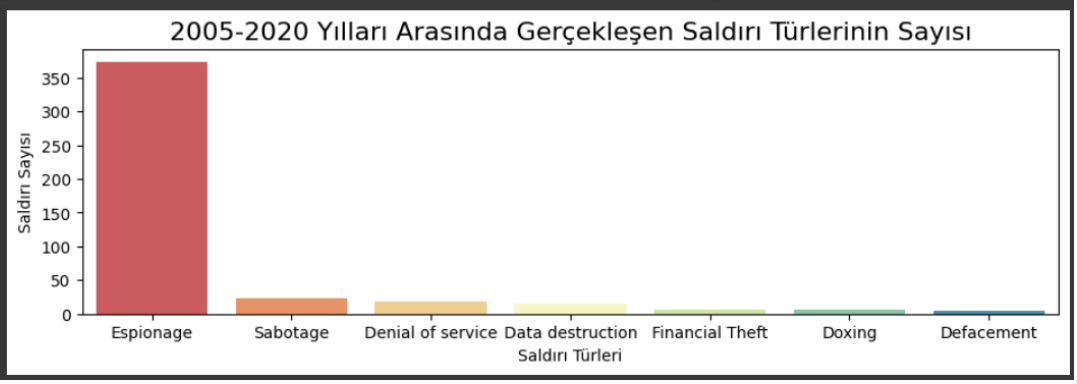

KISIM 1: VERİ FİLTRELEME

Bu aşamada veriler tarih, ülke ismi gibi spesifik kriterlere göre incelenerek görselleştirilmiştir.

Aşağıdaki görselde kullanıcının istediği yıla yönelik sistemde araştırma yapabilmesine olanak sağlayan basit bir arayüz tasarlanmıştır.

```
while True:
    girilen_yil = input("2005-2020 arasında bir tarih giriniz: ")
    try:
        girilen_yil = int(girilen_yil)
    except Exception as e:
        print(f"Hata!\n{e.args}")
        continue
    if 2005 <= girilen_yil <= 2020:
        girilen_yil = str(girilen_yil)
        break
    else:
        print("Geçersiz tarih girdiniz")

baslangic_tarihi = girilen_yil+'-01-01'
bitis_tarihi = girilen_yil+'-12-31'
```

```
2005-2020 arasında bir tarih giriniz: 2020
```

Date sütununda yer alan tarih verilerinin pandas kütüphanesi tarafından "tarih" olarak görülebilmesi ve bazı özel fonksiyonların kullanılabilmesi için pandas kütüphanesinde tanımlı "datetime" objesine dönüştürülmesi gerekmektedir.

Aşağıda bulunan görsellerde Date sütununda yer alan veriler pandas kütüphanesinde bulunan "datetime" objesine çevrilmiş, Date kısmı boş olan satırlar veri setinden silinmiş ve kullanıcının seçmiş olduğu yıl ile ilgili veri setinde filtreleme işlemi yapılmıştır.

```
# pandas datetime objesine çeviriyoruz (sort fonksiyonu vs. çalışması için)
df["Date"] = pd.to_datetime(df["Date"])
# Date kısmı boş olan satırların silinmesini sağlıyoruz
df_yillar = df[pd.notnull(df['Date'])]
```

```
# başlangıç ve bitiş tarihi aralığındaki tarihleri alıyorum
yil_verileri = (df_yillar['Date'] > baslangic_tarihi) & (df_yillar['Date'] <= bitis_tarihi)
# string değer olduğu için loc kullanıldı | yil_verileri sorgusuna göre verileri getir
yil_verileri = df_yillar.loc[yil_verileri]
yil_verileri = yil_verileri.reset_index(drop=True)
# siber olaylarla ilgili kaynaklara ihtiyaç duymadığımız için bu verileri siliyoruz
yil_verileri = yil_verileri.drop(['Sources_1', 'Sources_2', 'Sources_3'], axis=1)
```

Veri setinde, kullanıcın seçmiş olduğu yıl ile eşleşen verilerin içeriği hakkında genel bilgi sahibi olmak üzere WordCloud yapısı uygulanmıştır. (2020 Yılı Siber Olaylar İçeriği)

```
word_string = " ".join(yil_verileri['Description'].str.lower())
wordcloud = WordCloud(stopwords=STOPWORDS, colormap='winter', background_color="white").generate(word_string)

fig, ax = plt.subplots(1, 1, figsize=(8, 8))
plt.clf()
plt.imshow(wordcloud)

plt.axis('off')
plt.title(f'Word Cloud ({girilen_yil} Yılındaki Veriler)', fontsize=18, c='black')
plt.show()
```

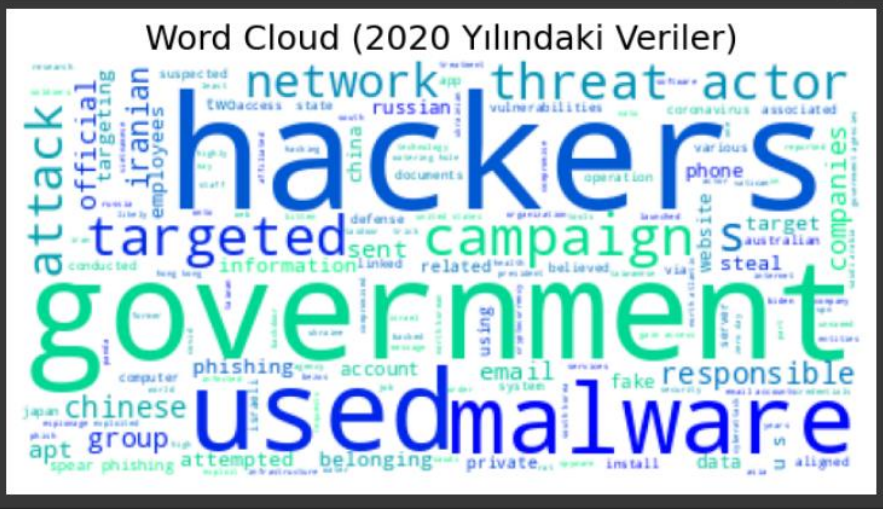

Kullanıcının seçmiş olduğu yıl ile ilgili tehdit aktörlerinin aktiviteleri incelenerek veriler sütun grafiğine yansıtılmıştır. (2020 Yılı Siber Güvenlik Tehdit Aktörleri Tablosu)

```
siber_olaylar_yil = yil_verileri["Affiliations"].value_counts()

fig, ax = plt.subplots(1, 1, figsize=(8, 9))
sns.countplot(data=yil_verileri, y='Affiliations', order=yil_verileri["Affiliations"].value_counts().index, palette="Spectral")

ax.set(xlabel='Saldırı Sayıları')
ax.set(ylabel='Tehdit Aktörleri')
plt.title(f'{girilen_yil} Yılındaki Tehdit Aktörleri', fontsize=16, c='black')
plt.subplots_adjust(left=0.56, right=0.97)
plt.show()
```

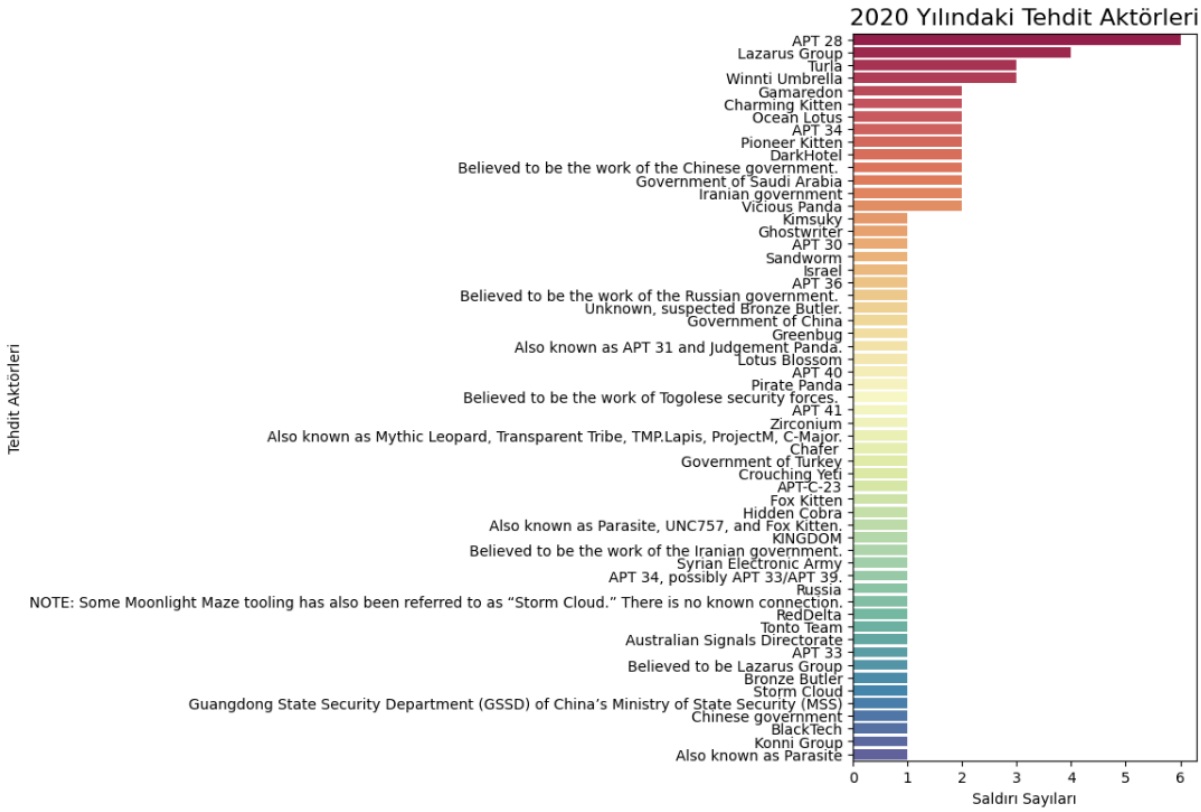

Aşağıdaki görselde kullanıcının seçtiği tarihte tehdit aktörerlerine en çok sponsor olan ülkelerin listelenmesine yönelik işlemler yapılmıştır. (2020 Yılı Siber Saldırılara / Tehdit Aktörlerine En Çok Sponsor Olan Ülkeler)

```
fig, ax = plt.subplots(1, 1, figsize=(6, 4))
sns.countplot(data=yil_verileri, y='Sponsor', order=yil_verileri["Sponsor"].value_counts().index, palette='Blues') # (alternatif: palette='mako')

ax.set(xlabel='Saldırı Sayıları') # alt kısım için yazı
ax.set(ylabel='Sponsorlar') # sol kısım için yazı

plt.title(f'{girilen_yil} Yılındaki Saldırılara En Çok Sponsor Olanlar', fontsize=16, c='black')
plt.subplots_adjust(left=0.25)
plt.show()
```

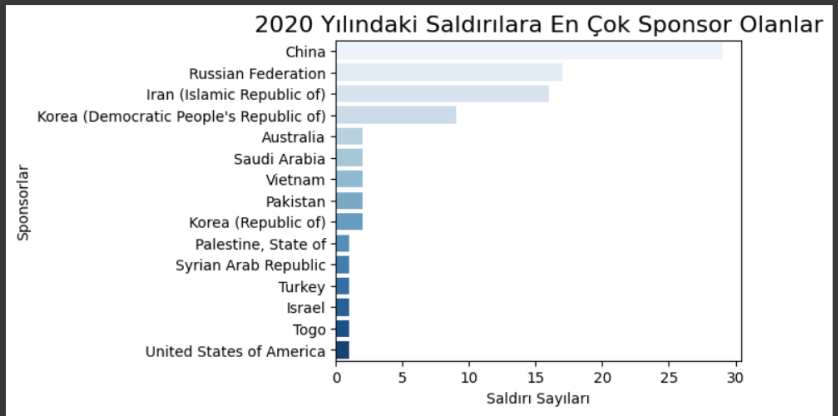

Kullanıcının seçmiş olduğu ülkeye göre, hükümetin maruz kaldığı siber saldırı sayısı listelenmiştir. (Türkiye'nin Yılara Göre Maruz Kaldığı Siber Saldırı Sayısı)

```
secilen_ulke = input("Lütfen ülkenin tam ismini giriniz: ")
ulke_kisaltmasi = input("Lütfen ülkenin kısaltmasını giriniz: ")

ulkedeki_veriler = df[df["Victims"].astype(str).str.contains('|'.join([secilen_ulke, ulke_kisaltmasi]), case=False)]
yila_gore_hacklenme = ulkedeki_veriler.groupby([df["Date"].dt.year]).agg({'Type': 'count'})

yila_gore_hacklenme.plot(style="-o", figsize=(6, 4), title=f"Yıllara Göre Maruz Kalınan Siber Saldırı Sayısı ({secilen_ulke})")
```

```
Lütfen ülkenin tam ismini giriniz: Turkey
Lütfen ülkenin kısaltmasını giriniz: TR
<Axes: title={'center': 'Yıllara Göre Maruz Kalınan Siber Saldırı Sayısı (Turkey)'}, xlabel='Date'>
```

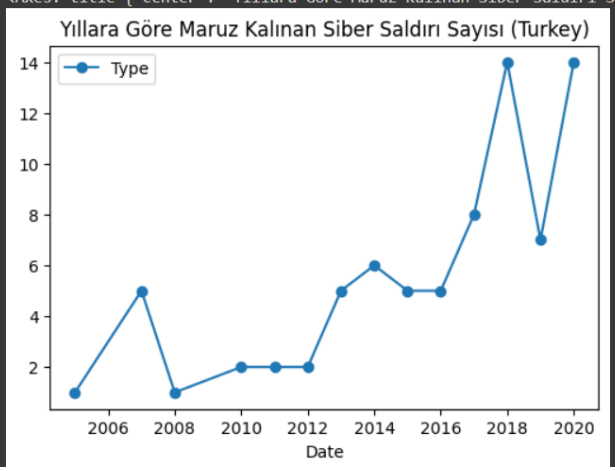

BÖLÜM 3
GELECEK YILA YÖNELİK VERİ TAHMİNİ

Bu aşamada veri tahminini gerçekleştirmek üzere yapay zekanın performansı artırmak istenmiş, buna bağlı olarak regresyon işlemleri uygulanmıştır.

Regresyon: Regresyon denklemi birden fazla değişken arasındaki ilişkiyi analiz etmeye ve buna bağlı olarak yeni tahminler üretilebilmesine olanak sağlar.

2020 yılındaki "Defacement" (arayüz görünümünü değiştirme) saldırısına yönelik verileri hesaplamak için kalan saldırı türleri bağımsız değişken olarak kabul edilir ve bu veriler kullanılarak bir regresyon denklemi oluşturulur. Bu sayede "Defacement" sayısı 2020 yılı için tahmin edilir. Ardından 2020 yılındaki gerçek değer ile arasındaki fark incelenir ve MSE, RMSE değerleri bulunur. Bu işlem bağımsız değişkenlere olduğu sürece her yılda tahmin yapmak için kullanılabilir.

MSE (Mean Squared Error): ortalama hatanın karesi
RMSE (Root-Mean-Square Deviation): ortalama karekök sapması

2020 yılındaki verilerin tahmin edilip karşılaştırılması ve 2021 yılındaki verilerin tahmin edilmesi aşamasında multiple linear regression (çoklu doğrusal regresyon) yöntemi kullanılmıştır. Tahmin ediciler ve yanıt arasında doğrusal bir ilişki olduğu ve basit yorumlanabilir bir model olduğu için bu regresyonda çoklu doğrusal yöntem tercih edilmiştir.

Gelecek yıl "Defacement" arayüz saldırısının ne kadar olacağını tahmin edebilmek için kullanacağımız regresyon denkleminde ihtiyaç duyduğumuz şey; hangi yıl hangi saldırıların ne kadar olduğudur. Bu yüzden aşağıdaki kod bloğunda sahip olunan verilerle yeni bir CSV dosyası yaratılmıştır.

```python
fields = list(df['Type'].value_counts().index)
fields.insert(0, "Year")
rows = []

for year in range(2005, 2021):
    baslangic_tarihi = f'{year}-01-01'
    bitis_tarihi = f'{year}-12-31'

    # başlangıç ve bitiş tarihi aralığındaki tarihleri alıyorum
    yil_verileri = (df_yillar['Date'] > baslangic_tarihi) & (df_yillar['Date'] <= bitis_tarihi)
    # string değer olduğu için loc kullanıldı | yil_verileri sorgusuna göre verileri getir
    yil_verileri = df_yillar.loc[yil_verileri]

    year_fields = list(yil_verileri["Type"].value_counts().index)
    year_rows = list(yil_verileri["Type"].value_counts().reset_index(name="count")["count"])
    year_output = list(zip(year_fields, year_rows))

    result = [0]*len(fields) # [0, 0, 0, 0, 0, 0, 0]
    result[0] = year # [2007, 0, 0, 0, 0, 0, 0]

    for i,f in enumerate(fields):
        for yf in year_output:
            if f == yf[0]:
                result[i] = yf[1]

    rows.append(result)

# CSV dosyamızın görüntüsü
print(fields)
for e in rows:
  print(e)

# dosya yazma işlemi
with open('predictdata.csv', 'w') as f:
    write = csv.writer(f)
    write.writerow(fields)
    write.writerows(rows)
```

Yukarıda yazılmış olan kodların çıktısı aşağıdaki şekilde olacaktır. Bahsi geçen çoklu doğrusal regresyon denklemi bu tablo üzerinde uygulanacaktır.

```
['Year', 'Espionage', 'Sabotage', 'Denial of service', 'Data destruction', 'Financial Theft', 'Doxing', 'Defacement']
[2005, 1, 0, 0, 0, 0, 0, 0]
[2006, 3, 0, 0, 0, 0, 0, 0]
[2007, 7, 0, 3, 0, 0, 0, 0]
[2008, 6, 0, 1, 0, 0, 0, 0]
[2009, 3, 0, 1, 0, 0, 0, 0]
[2010, 6, 1, 1, 0, 0, 0, 1]
[2011, 12, 0, 2, 0, 0, 0, 0]
[2012, 7, 0, 3, 2, 0, 0, 0]
[2013, 17, 0, 1, 0, 0, 0, 0]
[2014, 31, 1, 0, 1, 0, 1, 0]
[2015, 30, 1, 1, 0, 0, 0, 1]
[2016, 26, 2, 1, 3, 1, 0, 0]
[2017, 36, 2, 2, 2, 2, 0, 1]
[2018, 64, 5, 0, 0, 1, 5, 0]
[2019, 56, 4, 2, 4, 0, 0, 0]
[2020, 64, 6, 0, 2, 3, 0, 2]
```

Oluşturulan CSV uzantılı dosyanda işlemlerin gerçekleştirilebilmesi için pandas kütüphanesiyle okuma işlemi sağlanmıştır. Ek olarak makine öğrenmesi modelimizi eğitme aşamasında kullanacağımız X_train, y_train, X_test ve y_test isimli değişkenler tanımlanmıştır. X_train 2005-2019 yılları arasındaki defacement hariç saldırı türlerinin değerlerini, y_train 2005-2019 yılları arasındaki defacement saldırı türünün değerlerini içermektedir. Bu değişkenler modelimizi eğitmek için kullanılacaktır. X_test 2020 yılındaki defacement hariç saldırı türlerinin değerlerini, y_test ise 2020 yılındaki defacement saldırı değerini içermektedir.

Kullanılacak olan regresyon yönteminin doğruluk payını ölçebilmek adına, modelin önce var olan veriler üzerinde kullanılması amaçlanmaktadır. Model 2005-2019 yılları arasındaki veriler ile eğitildikten sonra, 2020 yılındaki defacement saldırı verisini tahmin etmesi beklenecektir.

```
predictdata = pd.read_csv('predictdata.csv')
X_train = predictdata.iloc[:15, 1:7] # 2005-2019 arası diğer saldırı türleri
y_train = predictdata.iloc[:15, 7] # 2005-2019 arası "defacement" saldırı değerleri
X_test = predictdata.iloc[15:16, 1:7] # 2020 yılındaki diğer saldırı türleri
y_test = predictdata.iloc[15:16, 7] # 2020 yılındaki "defacement" saldırı değeri

(X_train.shape, y_train.shape, X_test.shape, y_test.shape)
```

```
((15, 6), (15,), (1, 6), (1,))
```

Aşağıdaki görselde regresyon işlemi kullanılmak üzere class(sınıf) tanımlaması yapılmış ve fit() fonksiyonu 2005-2019 arasındaki veriler ile modelimizi eğitmek amacıyla kullanılmıştır. Ardından X_test verisi verilerek defacement verilerini tahmin etmesi beklenmiştir. Gerçek değerler (y_test) ile tahmin edilen değerler (y_predict_linear) arasındaki MSE ve RMSE değerleri incelenerek ekrana yazdırılmıştır. 0.1 ve 0.4 değerleriyle modelin gerçeğe yakın tahminler üreterek, doğruluk payının yüksek olduğu kanıtlanmıştır.

```python
reg = LinearRegression()

reg.fit(X_train, y_train) # 2005-2019 arasındaki tüm veriler

# 2020 yılındaki diğer saldırı türlerini vererek, 2020 yılındaki defacement saldırısını tahmin etmesini istiyoruz
y_pred_linear = reg.predict(X_test)


# tahmin edilen değer ile gerçek değer arasındaki hata payını buluyoruz
mse_linear = mean_squared_error(y_test, y_pred_linear)
rmse_linear = np.sqrt(mse_linear)


# MSE = ortalama hata karesi
# RMSE = ortalama hatanın karekökü

print(f"MSE: {mse_linear}\nRMSE: {rmse_linear}")
```

```
MSE: 0.19513216218378301
RMSE: 0.4417376621749418
```

Aynı yöntemler modelin 2021 tahmini oluşturmasını sağlamak için kullanılmıştır. Aşağıdaki görselde yapılan işlemler yer almaktadır.

```python
types = list(df['Type'].value_counts().index) # saldırı türleri

data_2021 = [0]*len(types) # [0, 0, 0, 0, 0, 0, 0]
data_2021[0] = "2021"

for i, type in enumerate(types):
    #sadece 1 satır için tahmin işlemi yapacağız, bu yüzden reshape kullanıyoruz
    X = predictdata["Year"].values.reshape(-1, 1)
    #saldırı türünün değerlerini kullanarak bir sonraki değerini tahmin etmeye çalışacağız
    y = predictdata[str(type)].values

    model = LinearRegression()
    model.fit(X, y)

    #tahmin işlemi için predict fonksiyonunun kullanarak 2021 yılındaki veriyi tahmin etmeye çalışıyoruz
    prediction_2021 = model.predict([[2021]])
    #çıkan sonucu saldırı türünün id'sine göre listeye ekliyoruz
    data_2021[i] = prediction_2021[0]

data_2021
```

```
[59.04999999999927,
 4.274999999999977,
 1.0500000000000007,
 2.400000000000034,
 1.4499999999999886,
 1.0999999999999943,
 0.7999999999999972]
```

Yukarıdaki kodlarda yapılmış işlemlerin çıktısı daha anlamlı bir şekilde aşağıdaki görselde yer almaktadır.

```
data2 = {"Types": types,
         "2021": data_2021}

df3 = pd.DataFrame(data2)

print(df3)
```

	Types	2021
0	Espionage	59.050
1	Sabotage	4.275
2	Denial of service	1.050
3	Data destruction	2.400
4	Financial Theft	1.450
5	Doxing	1.100
6	Defacement	0.800

Aşağıdaki görselde 2005-2020 yılları arasında gerçekleşen siber olayların türlerine göre sayısını gösteren çizgi grafiği yer almaktadır. (2005-2020 Yılları Arası Gerçekleşen Siber Olaylar)

```
predictdata.set_index("Year").plot(grid=True, figsize=(8, 3))
```

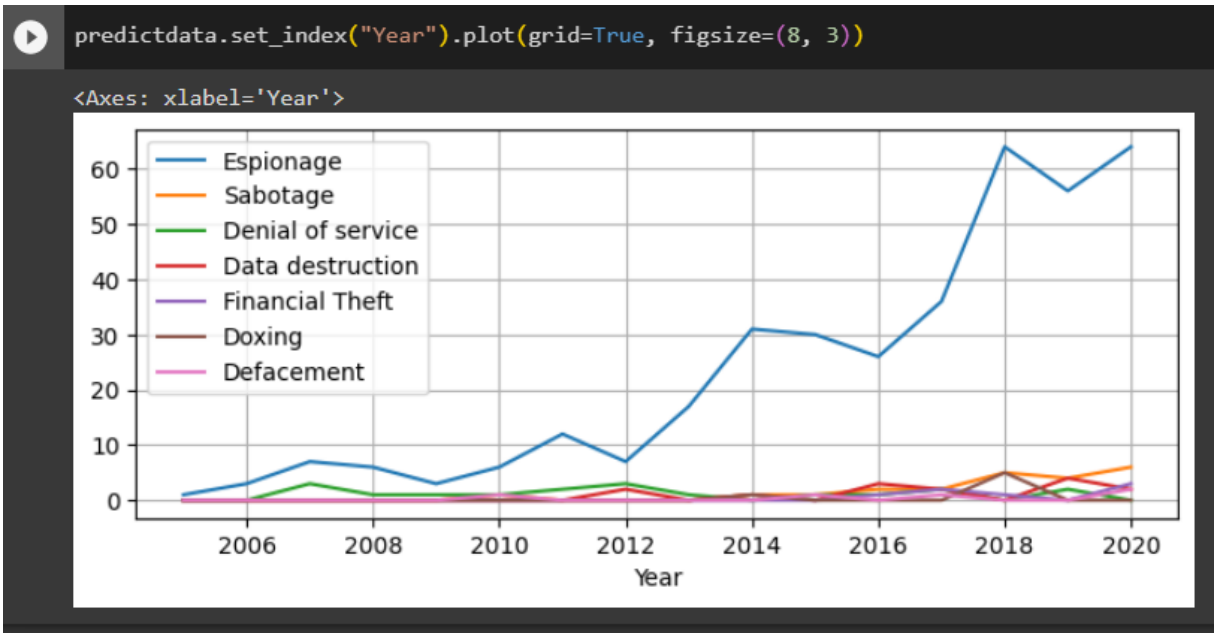

Aşağıda bulunan grafikte ise Makine Öğrenmesi ile geliştirilen Yapay Zeka modeli tarafından tahmin edilmiş olan 2021 yılı verilerine ait siber olayların sayısı türlerine göre belirtilmiştir. (2021 Yılı Gerçekleşmesi Öngörülen Siber Olayların Sayısı)

```
sns.lineplot(x=df3.head()["Types"], y=df3.head()["2021"], sizes=(5, 3))
sns.set(rc={'figure.figsize': (10, 5)})
```

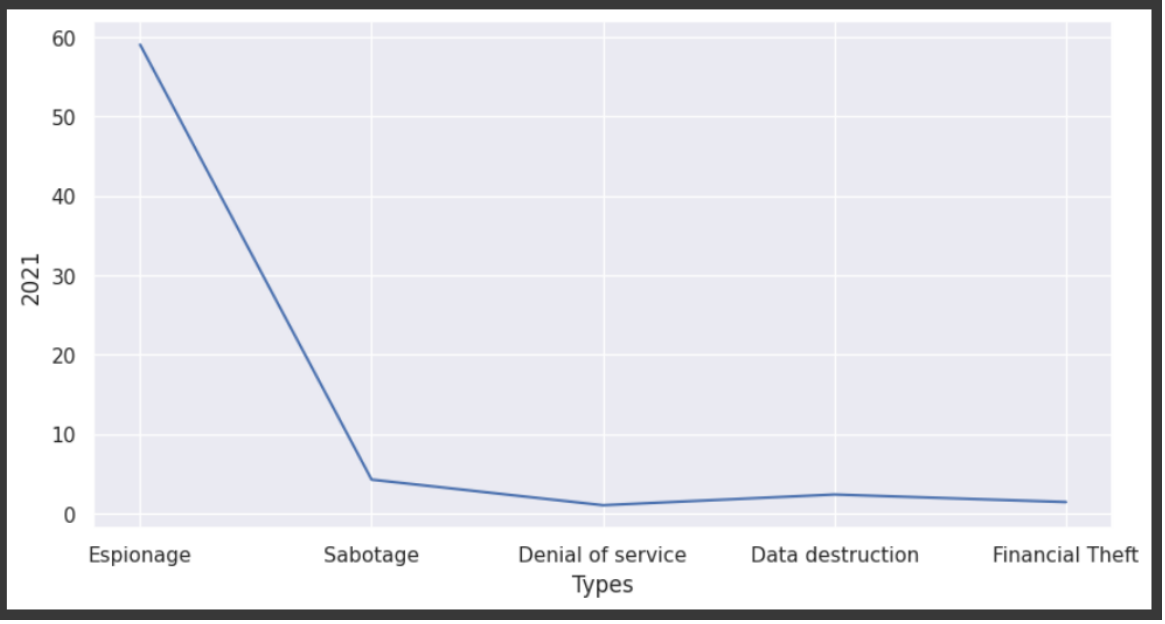

SONUÇ VE ÖNERİLER

Proje kapsamında Siber Güvenlik alanında gerçekleşen olayların belirli bir kısmı kullanılarak Makine Öğrenmesi ile Yapay Zeka modeli geliştirilmiştir. Geliştirilen yapay zeka modelinin gelecek yıldaki verilerin nasıl olacağına dair tahmin yapması sağlanmıştır. Yapay Zeka modeli yapılan testlere göre %86.5 doğruluk oranı vermektedir.

Doğruluk oranı hesaplama yöntemi:

(1.96 x RMSE) x 100

Projedeki veri setlerinin incelenmesi sonucu yapay zeka modelinin yaptığı tahminlere göre göre; 2021 yılı espionage (casusluk) türündeki siber saldırıların sayısı 59, sabotage (sabotaj) türündeki siber saldırıların sayısı 4, denial of service (sistem reddi) türündeki saldırıların sayısı 1, data destruction (veri imhası) türündeki saldırıların sayısı 2, financial theft (hırsızlık) türündeki saldırıların sayısı 1, doxing (gizli bilgileri yayma) türündeki saldırıların sayısı 1, defacement (arayüz görünümü değiştirme) türündeki saldırıların sayısı 0 olacaktır.

Siber Güvenlik sektöründe aktif olarak rol alan tüzel ve gerçek kişilerin işbu projede kullanılan veri setini gerçek bilgilerle besleyerek gelecek yıllara yönelik gerçek veri tahminleri yapılmasını sağlamaları beklenmektedir.

REFERANSLAR

[0]: https://www.kaggle.com/datasets/fireballbyedimyrnmom/cyber-incidents-up-to-2020 (21 Mayıs 2023)

[1]: https://github.com/ml6973/Course (21 Mayıs 2023)

[2]: https://realpython.com/linear-regression-in-python/#:~:text=You%20can%20predict%20the%20output,the%20intercept%20to%20the%20sum.&text=That's%20the%20prediction%20using%20a%20linear%20regression%20model (21 Mayıs 2023)

[3]: https://www.youtube.com/watch?v=A6jKo7OjAKw (21 Mayıs 2023)

[4]: https://dergipark.org.tr/tr/download/article-file/550950 (21 Mayıs 2023)